Class Weights pada Vision Transformer untuk Klasifikasi Citra Bencana Tidak Seimbang

Much Panji Laksono[1]*, Akmal Shaum Nadzirin[2], Rizka Dian Safitri[3], Thalita Nadia Azalai[4], Ricardus Anggi Pramunendar[5]
[1,2,3,4]Program Studi Teknik Informatika, Universitas Dian Nuswantoro, Jl. Imam Bonjol No. 207 Kota Semarang, Jawa Tengah, (024) 3517261
e-mail: *[1]**111202315237@mhs.dinus.ac.id**, [2]111202315256@mhs.dinus.ac.id, [3]111202315292@mhs.dinus.ac.id, [4]111202315291@mhs.dinus.ac.id, [5]*ricardus.anggi@dsn.dinus.ac.id*

Abstrak

Identifikasi dan klasifikasi jenis bencana alam secara cepat melalui pengolahan citra (computer vision) memainkan peran krusial dalam efektivitas mitigasi dan respons tanggap darurat. Penelitian ini mengevaluasi performa dua arsitektur Deep Learning utama: Convolutional Neural Network (CNN) dengan arsitektur ResNet-50 sebagai standar acuan (baseline), serta Vision Transformer (ViT) untuk mengklasifikasikan enam kategori bencana pada Comprehensive Disaster Dataset (CDD) yang mencakup 13.557 citra. Selain aspek arsitektur, studi ini secara mendalam menganalisis dua strategi penanganan data tidak seimbang, yaitu Random Undersampling pada tingkat data dan Class Weights pada tingkat algoritma. Temuan eksperimen mengonfirmasi bahwa integrasi metode Class Weights menghasilkan performa yang lebih stabil dan unggul dengan raihan Macro F1-Score sebesar 0,96, melampaui strategi Undersampling yang hanya mencapai 0,92 pada arsitektur terbaik. Keunggulan ini didorong oleh kemampuan model dalam mempertahankan integritas seluruh 13.557 informasi visual tanpa melakukan pemangkasan data. Penelitian ini memberikan rekomendasi empiris yang kuat dalam menentukan kombinasi arsitektur dan strategi penanganan ketimpangan data untuk aplikasi klasifikasi citra di sektor kebencanaan riil.

Kata kunci— *Class Weights, Undersampling, Imbalanced Data, Convolutional Neural Network, Vision Transformer, Klasifikasi Bencana Alam*

Abstract

Rapid identification and classification of natural disasters through computer vision play a crucial role in the effectiveness of mitigation and emergency response. This study evaluates the performance of two prominent Deep Learning architectures: Convolutional Neural Network (CNN) using the ResNet-50 architecture as a baseline, and Vision Transformer (ViT) for classifying six disaster categories within the Comprehensive Disaster Dataset (CDD), which comprises 13,557 images. Beyond the architectural aspects, this research provides an in-depth analysis of two imbalanced data handling strategies: Random Undersampling at the data level and Class Weights at the algorithmic level. Experimental findings confirm that the integration of the Class Weights method yields superior and more stable performance, achieving a Macro F1-Score of 0.96, outperforming the Undersampling strategy which only reached 0.92 on the best architecture. This advantage is driven by the model's ability to maintain the integrity of all 13,557 visual data points without discarding critical information. This study provides robust empirical recommendations for determining the optimal combination of architecture and imbalanced data handling strategies for real-world disaster image classification applications.

Keywords—*Class Weights, Undersampling, Imbalanced Data, Convolutional Neural Network, Vision Transformer, Natural Disaster Classification.*

1. PENDAHULUAN

Bencana alam merupakan fenomena yang tidak dapat diprediksi namun memiliki dampak destruktif yang masif terhadap infrastruktur dan kehidupan manusia. Sepanjang tahun 2023, eskalasi bencana secara global telah merenggut lebih dari 86.000 korban jiwa dan memicu kerugian ekonomi hingga 202,7 miliar dolar AS [1]. Tren ini menuntut integrasi teknologi prediktif yang lebih canggih untuk meminimalisir gap antara kejadian dan respons [2].

Di tengah situasi krisis yang menuntut respons cepat, proses identifikasi dan asesmen kerusakan (*damage assessment*) justru sering mengalami keterlambatan. Pemetaan wilayah terdampak melalui analisis citra satelit secara manual masih memakan waktu hingga berhari- hari, tergantung pada skala kerusakan [3]. Merespons urgensi tersebut, adopsi teknologi kecerdasan buatan, khususnya sistem *Computer Vision*, hadir sebagai solusi inovatif untuk mempercepat kinerja tim penyelamat dan akurasi alokasi bantuan logistik. Pemanfaatan sistem cerdas ini terbukti mampu memangkas waktu pemetaan hingga enam kali lipat lebih efisien dibandingkan metode konvensional [4][5][6]. Selama bertahun- tahun, algoritma *Convolutional Neural Network* (CNN), khususnya arsitektur ResNet-50, telah terbukti tangguh dan menjadi standar utama (*baseline*) dalam mengekstraksi fitur visual lokal dari sebuah gambar [7][8]. Namun, dominasi pendekatan konvensional tersebut kini mulai ditantang oleh kehadiran *Vision Transformer* (ViT), sebuah arsitektur mutakhir berbasis mekanisme *self-attention* yang diklaim lebih unggul dalam memodelkan konteks spasial global secara komprehensif [9][10].

Perkembangan kedua arsitektur ini didukung oleh literatur yang luas. Fondasi dari banyak pendekatan modern diletakkan oleh He dkk. [11] yang memperkenalkan arsitektur Residual Learning dengan mekanisme skip connections untuk mengatasi degradasi akurasi pada jaringan yang sangat dalam. Model ResNet yang dihasilkan mampu mencapai tingkat kesalahan 3,57% pada dataset ImageNet. Keberhasilan ResNet mendorong adopsi luas dalam berbagai tugas klasifikasi, termasuk penelitian Santoso dkk. [7] yang menerapkan ResNet-50 untuk deteksi katarak dengan akurasi 98,61%, dan Cao [8] yang memanfaatkannya untuk klasifikasi spesies kupu-kupu dengan akurasi 92,27%.

Dosovitskiy dkk. [10] membuktikan bahwa Vision Transformer (ViT) murni mampu menandingi model berbasis CNN pada data berskala besar. Habib dkk. [12] membandingkan ViT-B32 dengan EfficientNet-B0 dalam skenario evaluasi kerusakan bangunan pascabencana dengan hasil menunjukkan keunggulan ViT (akurasi 97,85%). Studi lain mengonfirmasi bahwa arsitektur transformer mulai menggeser dominasi CNN dalam tugas segmentasi kerusakan skala luas [13]. Bahmanyar dan Merkle [5] mengadaptasi YOLOv3 untuk mendeteksi manusia secara cepat dari citra udara, sementara Francini dkk. [6] menggabungkan deep learning dengan data GIS untuk identifikasi kawasan risiko bencana secara semi-otomatis.

Meskipun demikian, pengembangan model Deep Learning dalam studi kasus kebencanaan sering terbentur pada karakteristik data dunia nyata yang sangat tidak seimbang (highly imbalanced data) [12]. Pada Comprehensive Disaster Dataset (CDD), mayoritas citra merepresentasikan kondisi aman (Non Damage) sedangkan kelas kritis seperti Human Damage memiliki jumlah sampel yang sangat terbatas [14]. Jika model dilatih langsung menggunakan distribusi data tersebut, algoritma rentan mengalami fenomena Accuracy Paradox — model mencetak akurasi global yang tinggi namun gagal memprediksi kelas minoritas [15]. Ketimpangan data pada domain kebencanaan sering kali menyebabkan model gagal mengenali pola tekstur pada kelas langka [16]. False Negative pada kelas minoritas memiliki konsekuensi yang jauh lebih fatal dalam konteks manajemen bencana.

Untuk mengatasi permasalahan tersebut, terdapat dua pendekatan utama: penanganan pada tingkat data (data-level) melalui teknik Undersampling, serta penanganan pada tingkat algoritma (algorithm-level) menggunakan metode Class Weights yang memodifikasi fungsi kerugian (Loss Function) secara matematis [17][18]. Penelitian ini bertujuan mengkaji secara komprehensif efektivitas kedua pendekatan tersebut, sekaligus membandingkan performa arsitektur ResNet-50 dan ViT pada dataset CDD yang bersifat highly imbalanced.

Penelitian ini memberikan tiga kontribusi utama. Pertama, evaluasi empiris yang menguji dua dimensi keputusan perancangan — pilihan arsitektur (ResNet-50 versus ViT) dan strategi penanganan ketidakseimbangan data (Undersampling versus Class Weights) — pada dataset dengan rasio ketimpangan hingga 38:1. Pendekatan dua dimensi ini belum dilakukan secara terpadu dalam literatur sebelumnya [18][12]. Kedua, penelitian ini membuktikan bahwa strategi tingkat algoritma (Class Weights) menghasilkan performa yang lebih superior dibandingkan strategi tingkat data (Undersampling), dengan selisih Macro F1-Score sebesar 0,04 pada populasi uji yang lebih representatif. Ketiga, temuan ini menyediakan panduan praktis berbasis bukti (evidence-based guideline) bagi pengembang sistem kecerdasan buatan di sektor kebencanaan.

Celah penelitian utama terletak pada minimnya studi komparatif yang mengevaluasi stabilitas arsitektur Transformer terhadap arsitektur konvolusi konvensional pada rasio ketimpangan kelas yang ekstrem. Sebagian besar penelitian terdahulu, seperti studi oleh Habib dkk. [12], cenderung berfokus pada akurasi global namun belum mengeksplorasi degradasi performa pada kelas minoritas yang bersifat kritis. Penelitian ini hadir untuk mengisi ruang tersebut dengan mengoptimalkan strategi tingkat algoritma (Class Weights) guna mempertahankan kekayaan fitur visual asli tanpa membuang data referensi kontekstual yang penting.

2. METODE PENELITIAN

2.1 Alur Penelitian

Penelitian ini dirancang mengikuti alur sistematis sebagaimana diilustrasikan pada Gambar 1. Alur dimulai dari pengumpulan data publik, dilanjutkan dengan eksplorasi data, pra-pemrosesan, penanganan imbalanced data, pelatihan model, evaluasi, dan diakhiri dengan analisis komparatif untuk menghasilkan kesimpulan dan rekomendasi.



Gambar 1 Alur penelitian dari pengumpulan data hingga analisis komparatif

2.2 Deskripsi Dataset

Dataset yang digunakan adalah Comprehensive Disaster Dataset (CDD) dari repositori publik Kaggle (varpit94). Dataset berisi total 13.557 citra yang terbagi menjadi 6 kelas bencana sebagaimana ditunjukkan pada Tabel 1.

Tabel 1 Distribusi kelas pada Comprehensive Disaster Dataset (CDD)

Kategori Bencana	Jumlah Gambar
Non Damage	9.237

Damaged Infrastructure	1.454
Water Disaster	1.035
Fire Disaster	933
Land Disaster	657
Human Damage	241

Dataset CDD dibagi menggunakan strategi stratified split untuk memastikan proporsi setiap kelas terjaga secara konsisten pada setiap subset. Dari total 13.557 citra, sebesar 70% dialokasikan sebagai data latih (9.489 citra), 15% sebagai data validasi (2.034 citra), dan 15% sisanya sebagai data uji (2.034 citra). Strategi stratified dipilih mengingat distribusi kelas yang sangat timpang, sehingga setiap subset tetap mencerminkan rasio ketidakseimbangan asli sebesar 38:1 antara kelas Non Damage dan Human Damage. Pada skenario Undersampling, data uji berjumlah 218 citra pada distribusi yang seimbang secara artifisial.

2.3 Skenario Eksperimen

Penelitian ini dibagi ke dalam dua skenario eksperimen menggunakan library PyTorch dan Torchvision. Skenario pertama menerapkan Random Undersampling: seluruh sampel dari kelas-kelas mayoritas dipotong secara acak hingga jumlahnya setara dengan kelas terkecil (241 citra per kelas). Pendekatan ini menghasilkan dataset latih yang seimbang secara kuantitas, namun dengan konsekuensi hilangnya ribuan citra mayoritas.

Skenario kedua tetap memanfaatkan seluruh populasi data sebanyak 13.557 citra tanpa eliminasi sampel. Sebagai bentuk mitigasi terhadap ketimpangan, diterapkan strategi pemberian bobot penalti pada fungsi kerugian melalui metode Class Weights. Setiap kategori diberikan nilai bobot yang berbanding terbalik dengan frekuensi kemunculannya, sehingga model memberikan atensi lebih besar pada kategori yang jumlahnya sedikit. Metode ini terbukti lebih stabil dibandingkan metode generatif dalam menjaga integritas fitur asli pada dataset yang bersifat heterogen [19].

2.4 Landasan Teori Arsitektur

2. 4.1 Ketidak Seimbangan Data

Ketidakseimbangan data terjadi ketika distribusi sampel antar kelas dalam dataset memiliki perbedaan yang sangat ekstrem. Algoritma machine learning standar mengoptimalkan akurasi secara global, sehingga memaksa model memihak pada kelas mayoritas (majority bias) [18]. Dalam konteks klasifikasi bencana, kondisi ini berimplikasi pada kegagalan model mendeteksi kejadian bencana kritis yang tergolong kelas minoritas.

2. 4.2 Arsitektur Resnet-50

ResNet-50 adalah arsitektur CNN yang diperkenalkan oleh He et al. [11] dengan konsep residual connection atau skip connection untuk mengatasi masalah vanishing gradient pada jaringan yang sangat dalam. ResNet-50 beroperasi dengan prinsip konvolusi lokal, mengekstraksi fitur hierarkis mulai dari tepi dan tekstur pada lapisan awal hingga representasi semantik tingkat tinggi pada lapisan yang lebih dalam. Dalam penelitian ini, ResNet-50 berfungsi sebagai baseline dengan bobot awal dari dataset ImageNet, dan lapisan Fully Connected terakhir dimodifikasi dari 1.000 kelas menjadi 6 kelas sesuai kategori CDD.
Bobot kelas dihitung menggunakan Persamaan (1):

$$W_i = \frac{N}{C \times N_i} \quad ...(1)$$

di mana W_i adalah bobot untuk kelas ke-i, N adalah total sampel keseluruhan, C adalah jumlah kelas (6), dan N_i adalah jumlah sampel kelas ke-i.
Bobot tersebut kemudian diintegrasikan ke dalam fungsi kerugian entropi silang berbobot (*Weighted Cross-Entropy Loss*) pada Persamaan (2):

$$L = -\sum W_i \cdot y_i \cdot \log(\hat{y}_i) \quad ...(2)$$

di mana L adalah nilai kerugian total, W_i adalah bobot kelas ke-i dari Persamaan (1), y_i adalah label kelas sebenarnya, dan $\hat{y}_i$ adalah probabilitas prediksi model untuk kelas ke-i.

2. 4.3 Vision Transformer (ViT)

Vision Transformer adalah arsitektur yang pertama kali diperkenalkan oleh Dosovitskiy et al. [10] dengan mengaplikasikan mekanisme self-attention secara langsung pada klasifikasi citra. ViT memproses gambar input dengan cara membaginya menjadi sejumlah patch berukuran tetap 16×16 piksel, kemudian meratakan setiap patch menjadi sebuah vektor dan memperlakukannya layaknya token dalam model bahasa. Setiap patch embedding ditambah dengan positional embedding untuk mempertahankan informasi tata letak spasial, lalu diproses melalui serangkaian blok Multi-Head Self-Attention dan Feed-Forward Network [9]. Penelitian ini memanfaatkan ViT-B/16 yang telah di-pretrain pada ImageNet-21k dan kemudian di-fine-tune pada dataset CDD[12]

2.5 Metrik Evaluasi

Akurasi tidak relevan untuk data yang sangat timpang karena model yang selalu memprediksi kelas mayoritas pun akan menghasilkan akurasi semu yang tinggi. Oleh karena itu, performa model dinilai menggunakan tiga metrik utama:

$$Precision = \frac{TP}{TP + FP} \quad ...(3)$$

$$Recall = \frac{TP}{TP + FN} \quad ...(4)$$

$$F1\text{-}Score = \frac{2 \times Precision \times Recall}{Precision + Recall} \quad ...(5)$$

di mana TP adalah True Positive, FP adalah False Positive, dan FN adalah False Negative. Ketiga metrik ini dihitung secara macro-average untuk menjamin keadilan evaluasi di setiap kelas, tanpa memberikan bobot lebih pada kelas mayoritas.

2.5 Konfigurasi Pelatihan

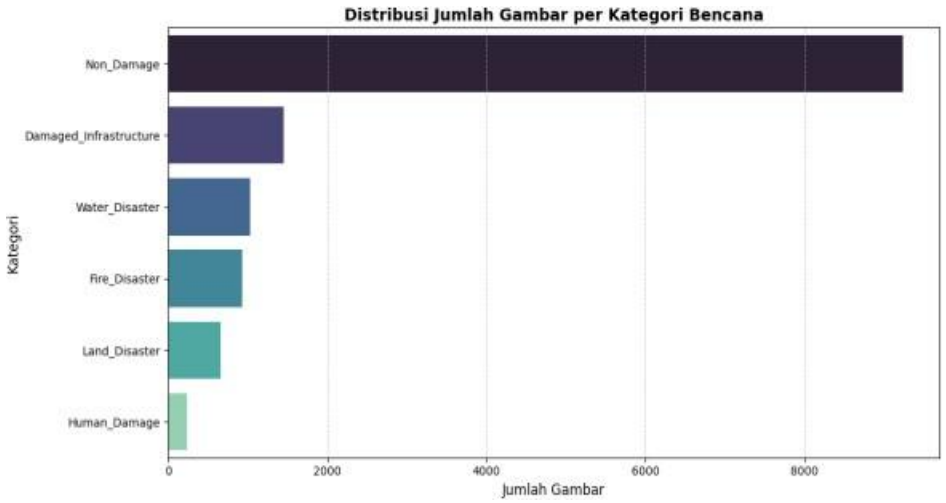
Tabel 2 Spesifikasi parameter pelatihan model

Parameter	Nilai	Keterangan
Optimizer	Adam	Adaptive learning rate optimizer
Learning Rate	0,001	Learning rate awal, tidak ada scheduler
Batch Size	32	Jumlah sampel per iterasi
Epoch	10	Jumlah siklus pelatihan penuh
Input Size	224 × 224 piksel	Standar ImageNet pre-training
Pre-trained Weight	ImageNet / ImageNet-21k	Sesuai arsitektur
Loss Function	CrossEntropyLoss / Weighted	Disesuaikan per skenario
Hardware	GPU NVIDIA Tesla T4	Platform Kaggle
Framework	PyTorch + Torchvision	Deep learning library
Metrik	Macro Precision, Recall, F1	Adil untuk data imbalanced

3. HASIL DAN PEMBAHASAN

3. 1 Eksplorasi Data (EDA)

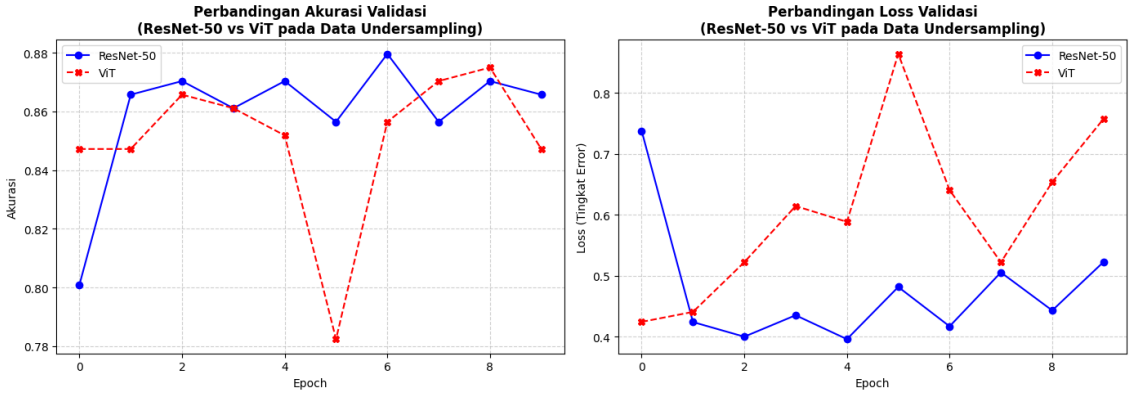
Distribusi frekuensi pada dataset CDD menunjukkan variasi jumlah sampel yang kontras antarkategori. Kelas Non Damage muncul sebagai kategori mayoritas yang mendominasi populasi data dengan proporsi mencapai 68%. Di sisi lain, kategori kritis seperti Human Damage memiliki representasi yang sangat terbatas, yakni hanya sebesar 1,8% dari keseluruhan dataset. Kesenjangan jumlah sampel yang lebar ini menciptakan tantangan teknis bagi arsitektur deep learning untuk mengenali fitur-fitur pada kelas minoritas tanpa terdistorsi oleh dominasi kelas mayoritas.



Gambar 2 Distribusi frekuensi kelas pada Comprehensive Disaster Dataset (CDD)

3. 2 Analisis Komparasi Performa pada Skenario Undersampling

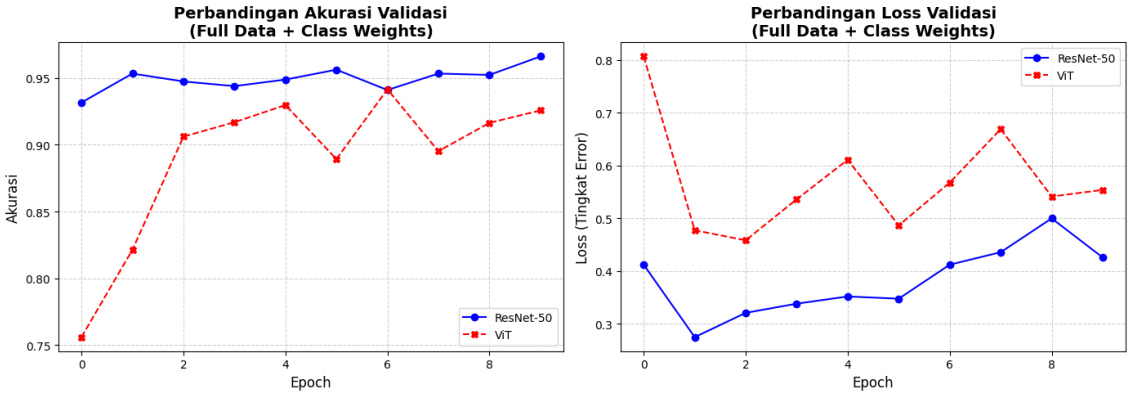
Skenario pertama menguji kemampuan ResNet-50 dan Vision Transformer (ViT) dalam kondisi data yang telah diseimbangkan melalui teknik Random Undersampling. Berdasarkan grafik akurasi validasi, terlihat bahwa kedua arsitektur menunjukkan pola konvergensi yang tidak stabil. ResNet-50 cenderung lebih konsisten di rentang akurasi 0,86–0,88, sedangkan ViT menunjukkan fluktuasi yang sangat ekstrem. Anomali paling signifikan terlihat pada epoch ke-5, di mana akurasi ViT terjun bebas hingga menyentuh angka 0,78. Fenomena degradasi performa yang tajam ini mengindikasikan bahwa pengurangan data secara ekstrem membuat mekanisme self-attention pada ViT gagal menemukan pola spasial yang konsisten.



Gambar 3 Distribusi frekuensi kelas pada Comprehensive Disaster Dataset (CDD)

3. 3 Analisis Komparasi Performa pada Skenario Class Weights

Skenario kedua mengevaluasi performa ResNet-50 dan ViT menggunakan dataset utuh dengan integrasi strategi Class Weights. ResNet-50 menunjukkan stabilitas yang sangat tinggi sejak awal epoch, dengan nilai akurasi yang konsisten berada di atas 0,93 dan mencapai puncaknya mendekati 0,97. Sebaliknya, ViT menunjukkan profil "progresivitas lambat" di mana akurasi dimulai dari angka yang relatif rendah (~0,75) sebelum akhirnya meningkat dan stabil pada rentang 0,90–0,93. Hal ini selaras dengan temuan bahwa learning rate pada transformer memerlukan fase warm-up yang lebih panjang untuk mencapai stabilitas pada data imbalanced [20]



Gambar 4 Kurva akurasi dan loss validasi pada skenario Class Weights

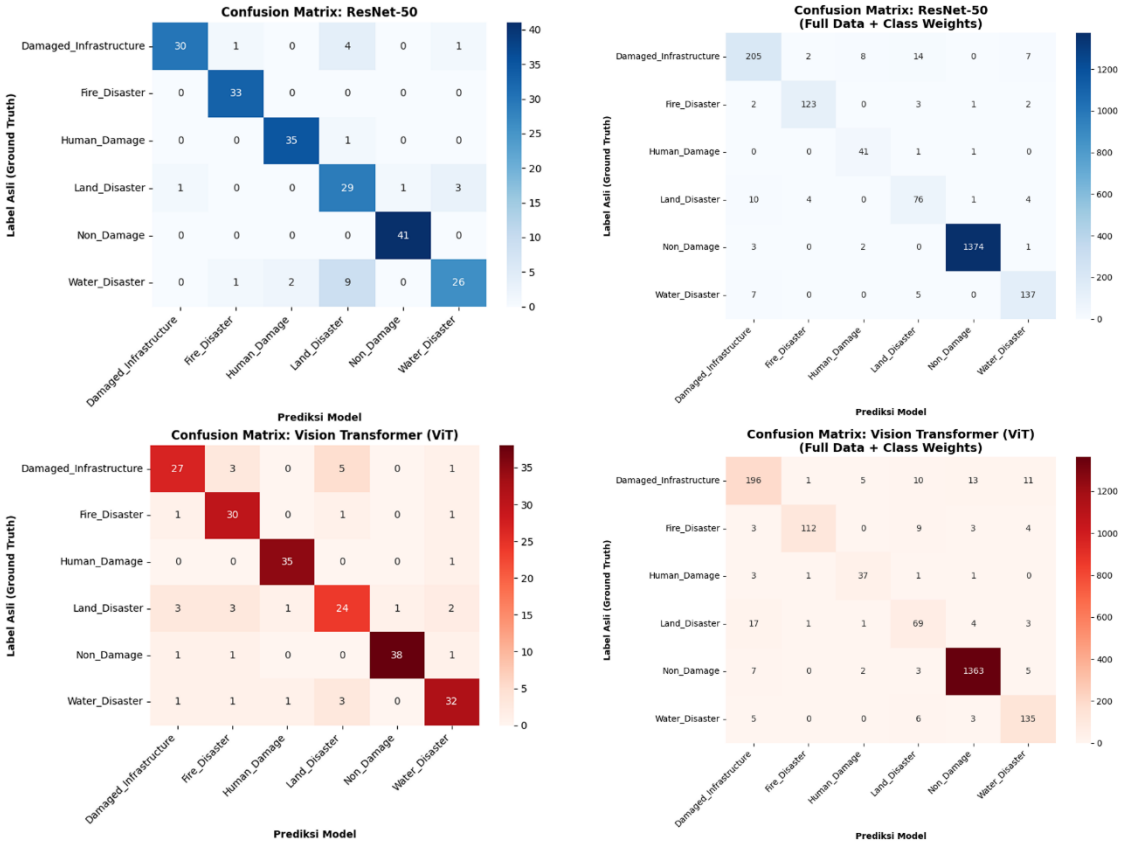
3. 4 Perbandingan Metode Undersampling dan Class Weights

Evaluasi komprehensif terhadap efektivitas penanganan ketimpangan data dilakukan dengan membandingkan hasil eksperimen pada skenario Random Undersampling (US) dan skenario Full Data dengan Class Weights (CW). Sebagaimana dirinci pada Tabel 3, metode Class Weights pada arsitektur ResNet-50 menunjukkan performa superior dengan raihan Macro Average F1-Score sebesar 0,96. Angka ini secara fundamental lebih unggul dibandingkan skenario Undersampling (0,92) karena model ini diuji pada populasi data yang jauh lebih besar dan kompleks (2.034 citra uji).

Tabel 3 Perbandingan F1-Score per kelas antar skenario eksperimen

Kategori	US-ResNet	US-ViT	CW-ResNet	CW-ViT
Damaged Infra.	0,87	0,79	0,89	0,82
Fire Disaster	0,99	0,93	0,92	0,91
Human Damage	0,97	0,96	0,85	0,83
Land Disaster	0,85	0,82	0,74	0,73
Non Damage	0,99	0,96	0,99	0,97
Water Disaster	0,86	0,84	0,91	0,84
Macro Avg	0,92	0,88	0,96	0,93

Perbedaan perilaku model antar kedua strategi ini terlihat semakin jelas melalui perbandingan matriks konfusi pada Gambar 5. Pada skenario Undersampling, matriks konfusi menunjukkan hasil yang secara nominal tampak sangat baik, namun model hanya dievaluasi pada sampel uji yang telah diseimbangkan secara artifisial (218 citra). Sebaliknya, matriks konfusi pada skenario Class Weights memperlihatkan stabilitas yang jauh lebih andal pada distribusi data uji utuh yang timpang secara masif (2.034 citra). ResNet-50 dengan Class Weights terbukti sangat tangguh dalam mempertahankan F1-Score hampir sempurna (0,99) pada 1.380 citra kelas mayoritas Non Damage, sembari tetap menjaga sensitivitas yang baik pada kategori bencana kritis seperti Water_Disaster (F1=0,91).



Gambar 5 Confusion matrix perbandingan keempat skenario eksperimen

3. 5 Perbandingan dengan Penelitian Terdahulu

Tabel 4 Perbandingan hasil dengan penelitian terdahulu

Peneliti & Tahun	Dataset	Metode	Akurasi (%)	Macro F1	Keterangan
Habib dkk. (2026)	Satelit Pascabencana	ViT-B32	97,85	N/A	Seimbang, 1 domain
Santoso dkk. (2025)	Citra Fundus	ResNet-50	98,61	N/A	Medis, tidak imbalanced
Cao (2025)	Kupu-kupu	ResNet-50+Aug	92,27	N/A	Fine-grained
Chamatidis dkk. (2024)	Sentinel Banjir	ViT	~90,00	N/A	Binary (banjir/tidak)
Penelitian ini	CDD 13.557 citra	ResNet-50+CW	96,00	0,96	Imbalanced 38:1
Penelitian ini	CDD 13.557 citra	ViT+CW	~93,00	0,93	Imbalanced 38:1

Jika dibandingkan dengan penelitian terdahulu yang relevan sebagaimana dirangkum pada Tabel 4, hasil yang diperoleh penelitian ini menunjukkan posisi yang kompetitif sekaligus memiliki keunikan konteks tersendiri. Habib dkk. [12] melaporkan akurasi sebesar 97,85% menggunakan ViT-B32 pada dataset kerusakan bangunan pascabencana yang bersifat seimbang dan berdomain tunggal. Santoso dkk. [7] mencapai akurasi 98,61% dengan ResNet-50 pada dataset medis yang tidak mengandung ketidakseimbangan kelas. Kedua studi tersebut, meskipun mencatat akurasi nominal yang lebih tinggi, beroperasi pada kondisi distribusi data yang jauh lebih ideal. Penelitian ini menghadapi tantangan yang secara fundamental lebih kompleks, yakni enam kategori bencana dengan rasio ketimpangan hingga 38:1. Dalam konteks tersebut, pencapaian Macro F1-Score sebesar 0,96 — metrik yang jauh lebih representatif untuk data timpang — membuktikan bahwa strategi Class Weights yang diterapkan mampu mengatasi tantangan tersebut secara efektif. Chamatidis dkk. [13] yang menggunakan ViT untuk deteksi banjir hanya mencapai akurasi ~90% pada tugas klasifikasi biner yang lebih sederhana, sementara penelitian ini mencapai 96% pada klasifikasi enam kelas dengan distribusi yang jauh lebih sulit. Perbandingan ini memperkuat argumen bahwa kontribusi penelitian ini terletak bukan pada pencapaian akurasi absolut tertinggi, melainkan pada demonstrasi bahwa sistem klasifikasi bencana multi-kelas yang andal tetap dapat dibangun di atas distribusi data nyata yang sangat timpang melalui strategi penanganan yang tepat di tingkat algoritma.

3. 6 Pembahasan

Esensi dari pengembangan sistem klasifikasi citra bencana yang andal terletak pada kemampuan model menjaga keseimbangan performa di tengah distribusi data yang tidak merata. Analisis kualitatif pada Gambar 6 memberikan bukti nyata mengenai risiko signifikan dari implementasi teknik Undersampling. Model sering melakukan identifikasi keliru (false positive); sebagai contoh, sistem mengklasifikasikan kerumunan individu di lingkungan publik yang aman sebagai kategori Human Damage. Kegagalan ini mempertegas bahwa penghapusan ribuan informasi visual dari kelas mayoritas mengakibatkan model kehilangan referensi kontekstual mengenai kondisi normal.

Sebaliknya, penggunaan strategi Class Weights pada kedua arsitektur menunjukkan konsistensi yang jauh lebih matang. Dengan tetap memanfaatkan seluruh 13.557 citra, ResNet-50 mencatatkan akurasi keseluruhan sebesar 96% dengan Macro Average F1-Score mencapai 0,96. Penggunaan bobot penalti yang proporsional pada fungsi kerugian terbukti efektif dalam

memitigasi Accuracy Paradox sehingga sistem tetap mampu mendeteksi kelas kritis dengan presisi tinggi tanpa mengorbankan pengenalan pada kelas mayoritas.



Gambar 6 Analisis kualitatif prediksi model pada skenario Undersampling dan Class Weights

3. 6 Keterbatasan Penelitian

Meskipun penelitian ini menghasilkan temuan yang menjanjikan, terdapat beberapa keterbatasan yang perlu diakui secara eksplisit. Pertama, penelitian ini hanya menggunakan satu dataset tunggal (CDD), sehingga kemampuan generalisasi temuan pada dataset bencana lain belum dapat dikonfirmasi sepenuhnya. Kedua, jumlah epoch pelatihan dibatasi pada 10 epoch akibat keterbatasan sumber daya komputasi, sehingga performa ViT yang memerlukan fase warm-up lebih panjang belum mencapai titik konvergensi optimalnya. Ketiga, penelitian ini tidak menyertakan metode oversampling seperti SMOTE sebagai skenario pembanding ketiga. Keempat, perbandingan dengan metode dari penelitian terdahulu bersifat indikatif karena perbedaan dataset, jumlah kelas, dan kondisi distribusi data.

4. KESIMPULAN

Berdasarkan seluruh rangkaian eksperimen pada Comprehensive Disaster Dataset (CDD) yang melibatkan 13.557 citra dan enam kategori bencana, penelitian ini menyimpulkan bahwa ketimpangan rasio kelas (class imbalance) berdampak signifikan terhadap degradasi performa algoritma deep learning jika tidak ditangani dengan strategi yang tepat. Hasil pengujian membuktikan bahwa penggunaan metode Class Weights pada fungsi kerugian (Weighted Cross-Entropy) jauh lebih optimal dan realistis dibandingkan teknik Random Undersampling. Strategi tingkat algoritma ini berhasil mencapai akurasi keseluruhan sebesar 96% dengan Macro Average F1-Score mencapai 0,96 pada arsitektur ResNet-50, serta 0,93 pada arsitektur ViT.

Meskipun ResNet-50 secara umum menunjukkan stabilitas metrik yang lebih konsisten pada dataset ini, Vision Transformer (ViT) memberikan nilai tambah yang signifikan melalui mekanisme self-attention yang mampu menangkap konteks spasial global secara komprehensif.

Hasil ini menegaskan bahwa strategi penanganan ketidakseimbangan data pada tingkat algoritma merupakan pendekatan yang paling realistis untuk aplikasi kecerdasan buatan di bidang kebencanaan. [21].

5. SARAN

Berdasarkan hasil analisis dan keterbatasan penelitian, beberapa saran untuk penelitian selanjutnya adalah sebagai berikut: (1) Perluasan dan variasi dataset — menguji performa model menggunakan berbagai dataset citra kebencanaan alternatif di luar CDD guna memvalidasi kapabilitas generalisasi arsitektur; (2) Optimasi hiperparameter dan LR Scheduler — mengeksplorasi penambahan epoch pelatihan serta penerapan learning rate scheduler seperti linear warmup dan cosine decay untuk mencapai titik konvergensi model yang lebih optimal; (3) Eksperimen strategi hibrida — mengintegrasikan teknik oversampling (SMOTE) atau augmentasi gambar sintetis bersama Class Weights untuk memperkuat representasi fitur visual pada kelas minoritas ekstrem; (4) Implementasi lightweight models dan data real-time — mengarahkan penelitian ke depan pada arsitektur yang lebih ringan serta pengujian model dalam skenario klasifikasi data secara real-time agar sistem siap dideploy pada perangkat edge langsung di lokasi krisis

UCAPAN TERIMA KASIH

Para penulis mengucapkan terima kasih kepada Program Studi Teknik Informatika Universitas Dian Nuswantoro atas dukungan akademik dan fasilitas yang diberikan selama pelaksanaan penelitian ini. Penulis juga menyampaikan apresiasi kepada kontributor dataset Comprehensive Disaster Dataset (CDD) di Kaggle (varpit94) yang telah menyediakan data secara terbuka untuk kepentingan penelitian. Para penulis menyatakan tidak terdapat konflik kepentingan dalam pelaksanaan penelitian maupun penulisan artikel ini. Dataset yang digunakan dalam penelitian ini tersedia secara publik dan dapat diakses melalui platform Kaggle: kaggle.com/datasets/varpit94/comprehensive-disaster-dataset.

DAFTAR PUSTAKA

[1] J. Ballester *et al.*, “Heat-related mortality in Europe during the summer of 2022,” *Nat. Med.*, vol. 29, no. 7, pp. 1857–1866, Jul. 2023, doi: 10.1038/s41591-023-02419-z.

[2] S. Ahmed, “Global Natural Disasters from 1900-2024: A Spatialtemporal Snapshots Disaggregation of Events and Impacts,” 2025. doi: 10.2139/ssrn.5241079.

[3] “UNOSAT_Preliminary_Assessment_Report_EQ20231008AFG_18102023”.

[4] UN Global Pulse, “AI from Google Research and UN boosts humanitarian disaster response: Wider coverage, faster damage assessments,” United Nations Global Pulse.

[5] R. Bahmanyar and N. Merkle, “SAVING LIVES FROM ABOVE: PERSON DETECTION IN DISASTER RESPONSE USING DEEP NEURAL NETWORKS,” *ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, vol. X-1/W1-2023, pp. 343–350, Dec. 2023, doi: 10.5194/isprs-annals-X-1-W1-2023-343-2023.

[6] M. Francini, C. Salvo, A. Viscomi, and A. Vitale, “A Deep Learning-Based Method for the Semi-Automatic Identification of Built-Up Areas within Risk Zones Using Aerial Imagery and Multi-Source GIS Data: An Application for Landslide Risk,” *Remote Sens. (Basel).*, vol. 14, no. 17, p. 4279, Aug. 2022, doi: 10.3390/rs14174279.

[7] I. Santoso, A. M. Manurung, and E. R. Subhiyakto, “Comparison of ResNet-50, EfficientNet-B1, and VGG-16 Algorithms for Cataract Eye Image Classification,” *Journal of Applied Informatics and Computing*, vol. 9, no. 2, pp. 284–294, Mar. 2025, doi: 10.30871/jaic.v9i2.8968.

[8] Y. Cao, “Fine-Grained Butterfly Image Classification Based on the ResNet-50 Model and Deep Learning,” in *Proceedings of the 2nd International Conference on Data*

Analysis and Machine Learning, SCITEPRESS - Science and Technology Publications, 2024, pp. 159–164. doi: 10.5220/0013511900004619.

[9] P. Mittal, V. Tanwar, B. Sharma, and D. P. Yadav, "Unleashing the Potential of Residual and Dual-Stream Transformers for the Remote Sensing Image Analysis," *J. Imaging*, vol. 11, no. 5, p. 156, May 2025, doi: 10.3390/jimaging11050156.

[10] A. Dosovitskiy *et al.*, "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale," Jun. 2021.

[11] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," Dec. 2015.

[12] J. Habib, Md. I. Hossain, Md. B. A. Z. Shammo, Md. T. W. Mulk, and E. Rubaiat, "Vision Transformer based Damage Assessment from Post-Disaster Satellite Imagery: An Applied Study on Hurricane Harvey," Feb. 12, 2026. doi: 10.21203/rs.3.rs-8642178/v1.

[13] I. Chamatidis, D. Istrati, and N. D. Lagaros, "Vision Transformer for Flood Detection Using Satellite Images from Sentinel-1 and Sentinel-2," *Water (Basel).*, vol. 16, no. 12, p. 1670, Jun. 2024, doi: 10.3390/w16121670.

[14] S. Gul, M. Elmahallawy, S. Madria, and A. Tripathy, "LPLgrad: Optimizing Active Learning Through Gradient Norm Sample Selection and Auxiliary Model Training," Nov. 2024.

[15] M. H. Fahreza, N. Z. Sipayung, I. W. Santoso, and S. Susilowati, "KOMPARASI SVM-LR BERBASIS INDOBERT DAN SMOTE-TOMEK PADA DETEKSI BUZZER," *Journal of Information System Management (JOISM)*, vol. 7, no. 2, pp. 320–329, Jan. 2026, doi: 10.24076/joism.2026v7i2.2435.

[16] A. Singh, "Context-Aware Synthetic Imagery for Disaster Response: Addressing Economic Bias in AI-Based Damage Assessment," 2025. doi: 10.2139/ssrn.5385441.

[17] P. Kaur and A. Gosain, "Issues and challenges of class imbalance problem in classification," *International Journal of Information Technology*, vol. 14, no. 1, pp. 539–545, Feb. 2022, doi: 10.1007/s41870-018-0251-8.

[18] M. Altalhan, A. Algarni, and M. Turki-Hadj Alouane, "Imbalanced Data Problem in Machine Learning: A Review," *IEEE Access*, vol. 13, pp. 13686–13699, 2025, doi: 10.1109/ACCESS.2025.3531662.

[19] M. Mujahid *et al.*, "Data oversampling and imbalanced datasets: an investigation of performance for machine learning and feature engineering," *J. Big Data*, vol. 11, no. 1, p. 87, Jun. 2024, doi: 10.1186/s40537-024-00943-4.

[20] Y. Li, J. Cao, Y. Xu, L. Zhu, and Z. Y. Dong, "Deep learning based on Transformer architecture for power system short-term voltage stability assessment with class imbalance," *Renewable and Sustainable Energy Reviews*, vol. 189, p. 113913, Jan. 2024, doi: 10.1016/j.rser.2023.113913.

[21] D. Shianios, P. S. Kolios, and C. Kyrkou, "DiRecNetV2: A Transformer-Enhanced Network for Aerial Disaster Recognition," *SN Comput. Sci.*, vol. 5, no. 6, p. 770, Aug. 2024, doi: 10.1007/s42979-024-03066-y.