Simulasi Sistem Deteksi Occupancy Berbasis YOLOv8 dan Arsitektur AIoT untuk Otomasi Kendali AC

Much Panji Laksono[1], Haidar Satria Hadi Wibowo[2],
Akmal Shaum Nadzirin[3], Arry Maulana Syarif[4]
Program Studi Teknik Informatika, Universitas Dian Nuswantoro, Jl. Imam Bonjol No. 207
Kota Semarang, Jawa Tengah, (024) 3517261
email: [1]**111202315237@mhs.dinus.ac.id**, [2]111202315241@mhs.dinus.ac.id,
[3]111202315256@mhs.dinus.ac.id, [4]arry.maulana@dsn.dinus.ac.id

Abstrak— Tingginya kepadatan pada fasilitas umum dan ruang kelas sering kali tidak mampu diakomodasi oleh pengaturan penyejuk udara (AC) konvensional yang bersifat statis, sehingga memicu ketidaknyamanan termal. Penelitian ini mengusulkan sebuah simulasi otomasi logika kendali AC adaptif berbasis *Edge Artificial Intelligence of Things* (AIoT) yang memanfaatkan algoritma *Computer Vision*. Model YOLOv8 Nano (YOLOv8n) dilatih menggunakan kombinasi dataset publik dan injeksi *negative samples* (ruangan kosong) agar mampu mendeteksi keberadaan dan menghitung jumlah penghuni secara spesifik. Pengujian dilakukan melalui simulasi arsitektur perangkat lunak yang memetakan hasil deteksi visual menjadi instruksi suhu: 24°C untuk okupansi rendah (1–5 orang) dan 22°C untuk okupansi tinggi (lebih dari 5 orang). Hasil eksperimen menunjukkan bahwa model YOLOv8n mencapai titik konvergensi optimal pada *epoch* ke-51 dengan skor mAP@50 sebesar 91%, Precision 92,6%, dan Recall 86,5%. Pengujian fungsional menggunakan metode *black box* menunjukkan bahwa logika sistem berhasil mentransmisikan instruksi suhu melalui *payload* MQTT dengan tingkat keberhasilan (*success rate*) rata-rata sebesar 96,38%. Dengan waktu inferensi sebesar 2,6ms per citra, simulasi arsitektur ini terbukti andal untuk dikembangkan sebagai fondasi otomatisasi ruang pintar secara *real-time*.

Kata Kunci: *YOLOv8, Computer Vision, Occupancy Detection, Kendali AC, Edge Computing, AIoT.*

Abstract— The high occupancy in public facilities and classrooms is often inadequately accommodated by conventional air conditioning (AC) settings that are static, thereby triggering thermal discomfort. This study proposes an adaptive AC control logic automation simulation based on the Edge Artificial Intelligence of Things (AIoT) using Computer Vision algorithms. The YOLOv8 Nano (YOLOv8n) model was trained using a combination of public datasets and the injection of negative samples (empty rooms) to enable specific detection and counting of room occupants. Testing was conducted through a software architecture simulation that maps visual detection results into temperature instructions: 24°C for low occupancy (1–5 people) and 22°C for high occupancy (more than 5 people). Experimental results show that the YOLOv8n model reached optimal convergence at epoch 51, achieving an mAP@50 score of 91%, a Precision of 92.6%, and a Recall of 86.5%. Functional testing using the black box method shows that the system logic successfully transmitted temperature instructions via MQTT payload with an average success rate of 96.38%. With an inference time of 2.6ms per image, this simulation architecture is proven to be reliable for development as a foundation for real-time smart room automation.

Keywords: *YOLOv8, Computer Vision, Occupancy Detection, AC Control, Edge Computing, AIoT.*

1. PENDAHULUAN

Banyak fasilitas umum, ruang perkantoran, maupun ruang kelas institusi pendidikan saat ini menjadikan penyejuk udara (AC) sebagai kebutuhan dasar untuk menunjang kenyamanan termal dan produktivitas pengguna. Namun, kenyamanan tersebut sering kali terkendala oleh operasional sistem tata udara konvensional yang kurang adaptif, di mana suhu hanya diatur secara statis tanpa mampu menyesuaikan diri dengan dinamika jumlah orang di dalam ruangan [1][2]. Akibatnya, ruangan menjadi terlalu dingin saat hanya diisi segelintir orang atau sebaliknya menjadi panas dan pengap ketika kapasitas ruangan mendadak penuh sesak. Untuk mengatasi permasalahan tersebut, pemanfaatan teknologi otomatisasi bangunan pintar (*smart building*) yang responsif terhadap kondisi lingkungan menjadi fokus krusial [3][4].

Meskipun berbagai penelitian terkait sistem kendali AC adaptif telah dikembangkan, sebagian besar pendekatan yang digunakan masih mengandalkan sensor sederhana seperti *Passive Infrared* (PIR) yang hanya mampu mendeteksi keberadaan gerakan tanpa memberikan informasi kuantitas penghuni secara spesifik [5]. Di sisi lain, riset yang mengintegrasikan algoritma deteksi objek terkini seperti YOLOv8 ke dalam arsitektur *Artificial Intelligence of Things* (AIoT) untuk pengendalian penyejuk ruangan umumnya masih terkendala pada validasi keandalan transmisi logika instruksinya sebelum masuk ke tahap implementasi perangkat keras. Oleh karena itu, diperlukan suatu penelitian yang berfokus pada perancangan simulasi sistem deteksi *occupancy* berbasis edge computing yang mampu menggabungkan akurasi hitungan manusia secara *real-time* dengan akurasi pengiriman instruksi kendali logika otomatisasi suhu yang andal.

Selain masalah pemborosan saat ruangan kosong, ketidaknyamanan termal juga sering muncul akibat dinamika jumlah penghuni di dalam suatu ruangan. Suhu statis yang diatur pada AC konvensional tidak mampu beradaptasi dengan perubahan jumlah orang yang ada; ruangan bisa menjadi sangat dingin hingga mengganggu konsentrasi saat hanya diisi oleh segelintir orang, dan sebaliknya menjadi panas serta pengap ketika ruangan mendadak penuh sesak. Kurangnya inisiatif kolektif dari penghuni untuk menyesuaikan suhu AC secara manual menjadi kendala utama pencapaian efisiensi energi. Untuk mengatasi permasalahan sosio-teknis tersebut, pemanfaatan *Internet of Things* (IoT) yang diintegrasikan dengan Kecerdasan Buatan (AI) telah terbukti menjadi pendekatan yang efektif untuk mewujudkan otomatisasi bangunan pintar (*smart building*) yang responsif terhadap kondisi lingkungannya [3] [4].

Berbagai penelitian terkait sistem kendali AC berbasis IoT dan deteksi keberadaan telah banyak dikembangkan, tetapi sebagian besar pendekatan yang digunakan masih mengandalkan sensor sederhana seperti Passive Infrared (PIR) [5] atau sensor gerak lainnya yang hanya mampu mendeteksi keberadaan manusia tanpa memberikan informasi jumlah penghuni secara akurat. Keterbatasan ini menyebabkan sistem belum mampu menyesuaikan kondisi termal ruangan secara optimal berdasarkan tingkat kepadatan aktual. Beberapa penelitian yang telah memanfaatkan teknologi visi komputer umumnya masih memiliki kendala pada aspek efisiensi komputasi dan implementasi real-time, terutama ketika diterapkan pada perangkat edge dengan sumber daya terbatas. Di sisi lain, integrasi antara algoritma deteksi objek terkini seperti YOLOv8 dengan sistem IoT untuk pengendalian AC secara adaptif dan otomatis masih belum banyak dieksplorasi secara komprehensif. Oleh karena itu, diperlukan suatu pendekatan yang mampu menggabungkan akurasi deteksi jumlah penghuni secara real-time dengan efisiensi komputasi berbasis edge serta integrasi IoT guna menghasilkan sistem kendali AC yang lebih cerdas, responsif, dan hemat energi.

Salah satu cabang AI yang paling optimal untuk mengukur kepadatan ruangan adalah *Computer Vision* melalui metode *occupancy detection*. Penggunaan kamera berbasis visi komputer memungkinkan sistem untuk tidak hanya mendeteksi keberadaan, tetapi juga menghitung jumlah manusia secara spesifik. Dalam perkembangannya, arsitektur You Only Look Once (YOLO) telah terbukti andal dan efisien dalam melakukan deteksi serta komputasi kepadatan objek secara real-time, sebagaimana keberhasilannya diimplementasikan pada penghitungan kepadatan kendaraan [6]. Keunggulan YOLOv8 dalam menghitung objek dengan akurasi tinggi ini menjadikannya sangat ideal untuk diadaptasi pada perangkat edge computing berdaya rendah guna mendeteksi kepadatan manusia di dalam ruangan.

Berdasarkan permasalahan dan celah penelitian yang telah diuraikan, penelitian ini bertujuan untuk merancang dan mengevaluasi sebuah simulasi arsitektur logika kendali AC adaptif berbasis *Edge* AIoT yang mengintegrasikan algoritma deteksi objek YOLOv8n dengan protokol komunikasi MQTT. Secara spesifik, penelitian ini memiliki tiga tujuan utama, yaitu: (1) melatih dan mengevaluasi performa model YOLOv8n dalam mendeteksi serta menghitung jumlah penghuni ruangan secara akurat pada tiga kategori okupansi; (2) merancang logika pemetaan hasil deteksi visual menjadi instruksi suhu AC secara otomatis dan mengujinya melalui simulasi transmisi *payload* MQTT; serta (3) mengukur kelayakan arsitektur yang diusulkan untuk diimplementasikan pada perangkat *edge computing* secara *real-time*. Kontribusi penelitian ini terletak pada integrasi antara akurasi deteksi berbasis *Computer Vision* dan validasi keandalan transmisi logika kendali, yang menjadi aspek yang belum banyak dieksplorasi secara komprehensif pada penelitian-penelitian sebelumnya. Berbeda dengan pendekatan berbasis sensor PIR yang hanya mampu mendeteksi keberadaan gerakan [5], maupun penelitian YOLO yang berfokus semata pada akurasi penghitungan objek tanpa validasi jalur instruksi kendali [6][7], penelitian ini menghadirkan pendekatan *end-to-end* yang menghubungkan tahap deteksi visual hingga simulasi eksekusi instruksi kendali pada jaringan IoT.

2. KAJIAN PUSTAKA

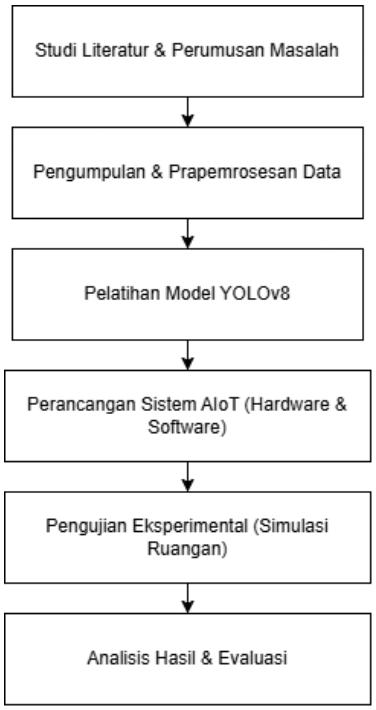
Beberapa penelitian terdahulu yang relevan dengan topik ini dapat dikelompokkan ke dalam tiga kategori utama. Kategori pertama adalah sistem deteksi okupansi berbasis sensor konvensional. Afandi [5] merancang sistem kendali AC menggunakan sensor DHT22 dan PIR pada mikrokontroler Arduino Nano, yang mampu mendeteksi keberadaan manusia namun tidak dapat mengidentifikasi jumlah penghuni secara spesifik. Hamdani [8] juga mengembangkan sistem kendali peralatan elektronik rumah tangga berbasis IoT menggunakan protokol MQTT, namun keputusan kendali masih bergantung pada masukan manual pengguna, bukan pada deteksi okupansi otomatis.

Kategori kedua adalah penelitian deteksi objek berbasis arsitektur YOLO untuk keperluan *counting*. Hidayat [6] mengimplementasikan YOLO untuk menghitung kepadatan kendaraan pada area parkir dengan hasil yang andal pada kondisi *real-time*. Pesik [7] menerapkan YOLOv8 untuk deteksi dan penghitungan objek manusia menggunakan pendekatan *Convolutional Neural Network*, sementara Puspita [9] menunjukkan bahwa augmentasi data tingkat lanjut mampu meningkatkan performa YOLO pada objek dengan tingkat oklusi tinggi. Zulkarnain dan Kusrini [10] turut membuktikan bahwa optimasi *hyperparameter* dan augmentasi data secara signifikan meningkatkan akurasi deteksi YOLO pada kondisi visual yang menantang, seperti pencahayaan rendah.

Kategori ketiga adalah penelitian integrasi IoT dan protokol MQTT untuk sistem kendali otomatis. Jimmy [11] menerapkan *Edge AI* untuk deteksi aktivitas penghuni pada *smart home* berbasis IoT, sedangkan Imam dan Zamzami [12] mengintegrasikan *Wireless Sensor Network* (WSN) dan IoT untuk sistem pemantauan rumah cerdas berbasis MQTT. Kusuma [13] membandingkan performa protokol HTTP dan MQTT pada sistem pemantauan berbasis IoT dan menemukan bahwa MQTT unggul dalam efisiensi transmisi data pada jaringan dengan sumber daya terbatas. Berdasarkan ketiga kategori tersebut, dapat disimpulkan bahwa penelitian mengenai deteksi okupansi berbasis YOLO yang secara langsung diintegrasikan dengan simulasi jalur transmisi instruksi kendali AC melalui MQTT masih menjadi celah penelitian yang belum banyak dieksplorasi, sehingga menjadi fokus utama dari penelitian ini.

3. METODOLOGI PENELITIAN

3.1. Alur Penelitian



Gambar 1 Diagram Alur Penelitian

3.2. Deskripsi Dataset

Dataset yang digunakan pada penelitian ini merupakan kombinasi dari dataset publik *Indoor Classroom Occupancy* (Roboflow Universe) dan pengumpulan data primer (*custom dataset*) yang direkam langsung pada ruang simulasi eksperimen. Dataset ini terdiri dari total 4.460 citra beresolusi 640x640 piksel, di mana setiap citra telah dianotasi dengan *bounding box* pada objek manusia. Penentuan ambang batas kuantitas manusia pada masing-masing kategori okupansi tersebut didasarkan pada perhitungan estimasi beban panas kumulatif (*heat load*) di dalam ruangan tertutup. Kategori *Empty Room* (0 orang) ditetapkan sebagai titik acuan regularisasi sistem untuk menonaktifkan AC secara otomatis saat ruangan kosong. Selanjutnya, batas *Low*

Occupancy (1 hingga 5 orang) merepresentasikan kondisi ruang dengan beban termal minimal, sehingga suhu optimal diatur pada 24°C untuk menjaga efisiensi daya. Sementara itu, ambang batas *High Occupancy* (lebih dari 5 orang) dipilih karena pada kuantitas tersebut, akumulasi panas metabolik dari tubuh manusia meningkat secara signifikan, yang mengharuskan sistem menurunkan suhu secara dinamis ke 22°C demi mempertahankan ekuilibrium kenyamanan termal ruangan.

Tabel 1 Distribusi Dataset

Kategori Okupansi	**Kondisi Ruangan**	**Jumlah Citra**
Empty Room	0 Orang (Kosong)	113
Low Occupancy	1 - 5 Orang	3.663
High Occupancy	> 5 Orang (Padat)	684
Total		4.460



Gambar 2 Sampel Dataset

Dataset yang telah dikumpulkan selanjutnya dibagi ke dalam tiga subset menggunakan rasio 80:10:10 untuk keperluan pelatihan (*training*), validasi (*validation*), dan pengujian (*testing*). Pembagian ini dilakukan secara acak namun tetap mempertahankan proporsi antar kelas okupansi (*stratified split*) agar distribusi data pada tahap validasi dan pengujian tetap merepresentasikan sebaran data asli. Proses anotasi *bounding box* pada seluruh citra dilakukan menggunakan platform Roboflow, dengan format label yang disesuaikan dengan standar arsitektur YOLO. Ketidakseimbangan kelas (*class imbalance*) yang terlihat pada Tabel 1 sengaja tidak diatasi melalui teknik *undersampling* pada kelas *Low Occupancy*, melainkan dikompensasi melalui teknik augmentasi data pada kelas minoritas (*Empty Room* dan *High Occupancy*) sebagaimana dijelaskan pada subbagian Akuisisi dan Prapemrosesan Data Visual, guna mempertahankan variasi kondisi nyata yang direpresentasikan oleh data mayoritas.

3.3. Arsitektur AIoT dan *Edge Computing*

Arsitektur sistem logika kendali penyejuk udara (AC) cerdas yang diusulkan pada penelitian ini dibangun menggunakan pendekatan *edge computing*, di mana seluruh inferensi visual dari algoritma YOLOv8 diproses secara lokal guna memangkas waktu tunda (*latency*) pengiriman data dan menjaga privasi penghuni ruangan [11][14]. Setelah tingkat kepadatan ruangan berhasil dikalkulasi oleh *edge device*, instruksi penyesuaian suhu diteruskan menuju topik jaringan menggunakan protokol *Message Queuing Telemetry Transport* (MQTT) [12][13]. Pada penelitian ini, fungsionalitas komponen mikrokontroler aktuator (ESP32) dan modul emulasi sinyal *Infrared* (IR) transmitter disimulasikan sepenuhnya dalam ranah perangkat lunak (*software architecture simulation*) untuk memvalidasi presisi pengiriman pesan perintah sebelum nantinya diterapkan pada perangkat keras fisik di lapangan.

3.4. Akuisisi dan Prapemrosesan Data Visual

Tahap akuisisi data visual pada penelitian ini dilakukan dengan mengombinasikan *dataset* publik dengan pengumpulan citra primer yang diambil menggunakan modul kamera *edge* berdaya rendah. Pengambilan citra secara langsung ini krusial untuk mengevaluasi batasan kinerja perangkat IoT[15], sekaligus merepresentasikan dinamika kepadatan nyata yang sangat dibutuhkan untuk melatih model YOLOv8 dalam mendeteksi dan menghitung objek manusia secara presisi [7]. Untuk meningkatkan ketahanan (*robustness*) model terhadap fluktuasi pencahayaan ruangan—seperti kondisi redup atau efek cahaya latar (*backlight*)—tahap prapemrosesan menerapkan teknik augmentasi citra. Implementasi augmentasi data ini terbukti secara empiris mampu mempertahankan akurasi deteksi secara signifikan pada kondisi lingkungan dengan visibilitas yang rendah [10] **.** Selanjutnya, penerapan augmentasi data tingkat lanjut (*advanced data augmentation*) juga diaplikasikan untuk menekan tingkat *False Negative* pada kasus oklusi tinggi, yakni saat kapasitas ruangan penuh dan objek saling tumpang tindih. Pendekatan ini telah tervalidasi esensial dalam menjaga performa arsitektur YOLO pada skenario deteksi objek yang sangat dinamis dan saling berhimpitan [9]. Seluruh citra kemudian dianotasi dan direduksi resolusinya sesuai standar arsitektur YOLO, lalu didistribusikan ke dalam himpunan data pelatihan, validasi, dan pengujian untuk evaluasi model yang objektif.

3.5. Pemodelan dan Pelatihan YOLOv8

Proses inferensi visual pada penelitian ini mengadopsi arsitektur YOLOv8, karena model ini menawarkan efisiensi komputasi dan keseimbangan optimal antara kecepatan (*real-time processing*) serta akurasi yang ideal untuk penerapan di perangkat *edge* [16]. Untuk memaksimalkan presisi pelokalan objek manusia di dalam ruangan, model memanfaatkan arsitektur *Convolutional Neural Network* (CNN) yang terintegrasi pada YOLOv8. Penggunaan arsitektur ini secara empiris telah terbukti sangat andal dalam melakukan deteksi sekaligus penghitungan jumlah manusia secara spesifik dan akurat [7]. Konfigurasi hiperparameter memegang peranan krusial dalam pelatihan ini; pembaruan bobot model dieksekusi menggunakan algoritma optimasi AdamW dengan *learning rate* adaptif. Algoritma ini dipilih karena secara komparatif telah terbukti memberikan stabilitas konvergensi dan tingkat performa yang lebih superior pada arsitektur *deep learning* berbasis CNN dibandingkan *Stochastic Gradient Descent* (SGD) konvensional [17]. Pelatihan model dijalankan hingga 300 *epoch* dengan ukuran *batch* 16, dipadukan dengan mekanisme *Early Stopping* guna mencegah terjadinya *overfitting*. Pendekatan evaluasi dan penyesuaian hiperparameter ini sejalan dengan analisis optimasi pada keluarga arsitektur YOLO, yang memastikan model mampu mencapai titik generalisasi optimal tanpa memboroskan sumber daya komputasi perangkat keras [18]. Evaluasi performa model dilakukan menggunakan empat metrik utama, yaitu *Precision*, *Recall*, F1-*Score*, dan *mean Average Precision* (mAP@50). *Precision* didefinisikan sebagai rasio antara jumlah prediksi positif yang benar (*True Positive*/TP) terhadap keseluruhan prediksi positif yang dihasilkan model (TP ditambah *False Positive*/FP), yang mengindikasikan seberapa andal model dalam menghindari kesalahan deteksi palsu. Sementara itu, *Recall* dihitung sebagai rasio TP terhadap keseluruhan objek positif aktual (TP ditambah *False Negative*/FN), yang merepresentasikan kemampuan model dalam mengenali seluruh objek manusia yang sesungguhnya ada di dalam citra. Kedua metrik ini saling melengkapi F1-*Score* dan mAP@50 yang telah dijelaskan pada subbagian Skenario Pengujian dan Metrik Evaluasi, sehingga performa model dapat dinilai secara komprehensif baik dari sisi akurasi lokalisasi maupun sensitivitas deteksi.

3.6. Algoritma Kendali AC Adaptif

Logika kendali pada sistem ini dirancang untuk memetakan jumlah penghuni hasil deteksi YOLOv8 menjadi instruksi suhu penyejuk udara secara otomatis. Penentuan ambang batas suhu target didasarkan pada analisis standar kenyamanan termal ruangan yang berfokus pada ekuilibrium suhu di lingkungan akademis atau perkantoran [19]. Sistem menetapkan rekomendasi suhu target 24°C saat okupansi rendah (1–5 orang) dan secara otomatis menurunkannya menjadi 22°C saat kepadatan meningkat (lebih dari 5 orang) guna mengompensasi peningkatan akumulasi beban panas dari kerumunan [20][8]. Rekonstruksi instruksi penyesuaian suhu tersebut dimodelkan dalam bentuk kode biner yang mereplikasi sinyal *remote* bawaan AC, di mana efektivitas pengirimannya dievaluasi melalui skenario simulasi transmisi data tanpa melakukan modifikasi fisik pada sirkuit internal unit AC [21]. Secara garis besar, logika kendali adaptif yang diusulkan dijalankan melalui enam tahapan algoritmik sebagai berikut: (1) *edge device* menangkap citra ruangan secara *real-time* melalui modul kamera; (2) citra diproses oleh model YOLOv8n untuk mendeteksi dan menghitung jumlah objek manusia; (3) hasil penghitungan diklasifikasikan ke dalam salah satu dari tiga kategori okupansi, yaitu *Empty Room*, *Low Occupancy*, atau *High Occupancy*; (4) kategori okupansi tersebut dipetakan ke instruksi suhu target sesuai dengan aturan yang telah ditetapkan (24°C untuk okupansi rendah dan 22°C untuk okupansi tinggi, serta status nonaktif untuk ruangan kosong); (5) instruksi suhu dikonversi menjadi *payload* data string yang merepresentasikan kode sinyal *remote* AC; dan (6) *payload* tersebut dipublikasikan (*publish*) ke topik jaringan MQTT untuk selanjutnya diteruskan oleh *broker* menuju *subscriber* yang mensimulasikan modul aktuator. Keenam tahapan ini dieksekusi secara berulang pada setiap siklus deteksi untuk memastikan respons kendali tetap adaptif terhadap perubahan dinamika okupansi ruangan.

3.7. Skenario Pengujian dan Metrik Evaluasi

Skenario pengujian pada penelitian ini dievaluasi melalui dua pilar utama: kinerja akurasi algoritma visi komputer dan keandalan fungsional logika kendali menggunakan metode *Black Box Testing*. Evaluasi kinerja deteksi YOLOv8 dikuantifikasi menggunakan metrik dasar *Precision*, *Recall*, F1-*Score*, dan *mean Average Precision* (mAP) pada ambang batas *Intersection over Union* (IoU) sebesar 50% [22][4]. Rumus untuk menghitung F1-*Score* didefinisikan sebagai berikut:

$$F_1 = 2 \times \frac{Precision \times Recall}{Precision \times Recall}$$

Selain itu, performa lokalisasi dan deteksi model secara keseluruhan divalidasi menggunakan *mean Average Precision* (mAP), yang menghitung rata-rata *Average Precision* (AP) untuk setiap kelas objek yang dideteksi pada berbagai ambang batas *Intersection over Union* (IoU) [4].

$$mAP = \frac{1}{N}\sum_{i=1}^{N} AP_i$$

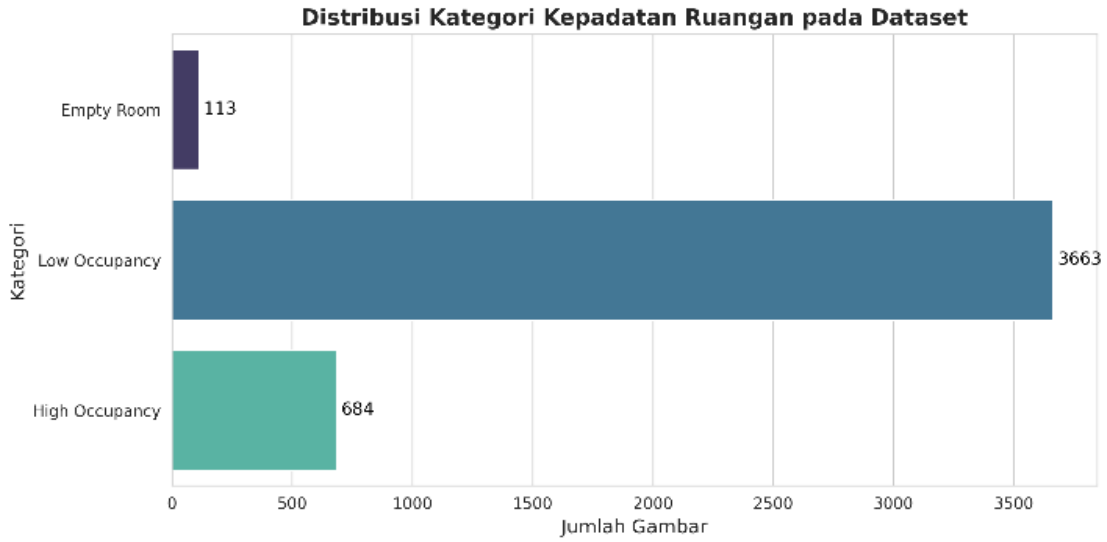
Pilar pengujian kedua difokuskan pada pengujian fungsionalitas sistem menggunakan skenario *Black Box Testing* untuk mengukur tingkat sukses transmisi data kendali. Pengujian ini mendefinisikan status "Sukses" jika *payload* data string instruksi suhu yang dipublikasikan oleh *publisher* via MQTT broker cocok secara tepat (100% *match*) dengan kelas kepadatan hasil deteksi visual (misalnya, mengirim perintah suhu 24°C saat model mendeteksi 3 orang). Sebaliknya, status "Gagal" ditetapkan jika terjadi *mismatch* logika kendali, kesalahan pembacaan kelas objek, atau instruksi gagal dikirimkan (*packet loss*). Skenario *scanning* diuji secara berulang menggunakan sampel data uji dari masing-masing kelas okupansi (*Empty Room*, *Low Occupancy*, dan *High Occupancy*) untuk menghitung nilai persentase tingkat keberhasilan (*success rate*) sistem secara *end-to-end*. Jumlah 800 skenario pengujian pada tahap *Black Box Testing* ditentukan secara proporsional terhadap distribusi kelas pada dataset pengujian, dengan tujuan agar hasil evaluasi mencerminkan kondisi distribusi data yang sesungguhnya. Tingkat keberhasilan (*success rate*) sistem secara keseluruhan dihitung menggunakan persamaan berikut: *success rate* = (jumlah skenario Sukses ÷ jumlah total skenario) × 100%. Perhitungan ini dilakukan baik secara agregat untuk keseluruhan sistem maupun secara terpisah untuk masing-masing kategori okupansi, guna mengidentifikasi kategori mana yang memiliki tingkat kegagalan transmisi instruksi tertinggi.

4. HASIL DAN PEMBAHASAN

4.1. Analisis Data Eksploratif

Sebelum memasuki tahap pelatihan model, analisis data eksploratif dilakukan terhadap dataset gabungan (*indoor person detection* dari Roboflow dan injeksi *negative samples* dari MIT Indoor Scenes) yang telah disiapkan di lingkungan Kaggle. Berdasarkan skrip ekstraksi dan prapemrosesan data otomatis yang dijalankan, diperoleh data final yang siap digunakan untuk *training* YOLOv8n.

Karakteristik data berdasarkan jumlah objek (manusia) per citra dipetakan untuk melihat distribusinya terhadap skenario kenyamanan termal yang diusulkan. Hasil pemetaan distribusi kelas dataset ditunjukkan pada Gambar:



Gambar 3 Digram Batang Distribusi Dataset

Berdasarkan gambar, dataset didominasi oleh kategori *Low Occupancy* (1-5 orang) sebanyak 3.663 citra, disusul *High Occupancy* (>5 orang) sebanyak 684 citra, dan *Empty Room* (0 orang) sebanyak 113 citra. Meskipun terjadi ketidakseimbangan kelas (*class imbalance*) di mana kelas *Low Occupancy* sangat dominan, injeksi 113 citra ruangan kosong (*negative samples*) dianggap krusial secara metodologis. Kehadiran data *Empty Room* berfungsi sebagai fitur regularisasi agar model YOLOv8n tidak hanya belajar mengenali fitur manusia, tetapi juga belajar mengenali karakteristik latar belakang ruangan target saat kosong, sehingga dapat meminimalisir potensi kesalahan deteksi (*False Positive*) saat sistem diimplementasikan secara *real-time*. Ketidakseimbangan distribusi kelas tersebut ditangani pada tahap pelatihan melalui kombinasi augmentasi data tingkat lanjut pada kelas minoritas dan injeksi *negative samples* yang proporsinya sengaja diperbesar, alih-alih menerapkan *undersampling* pada kelas *Low Occupancy* yang berpotensi mengurangi variasi data pelatihan secara signifikan. Strategi ini sejalan dengan temuan Zulkarnain dan Kusrini [10] maupun Puspita [9] yang membuktikan bahwa augmentasi data lebih efektif mempertahankan generalisasi model dibandingkan pengurangan data pada kelas mayoritas, khususnya pada kasus deteksi objek dengan tingkat oklusi dan variasi visual yang tinggi.

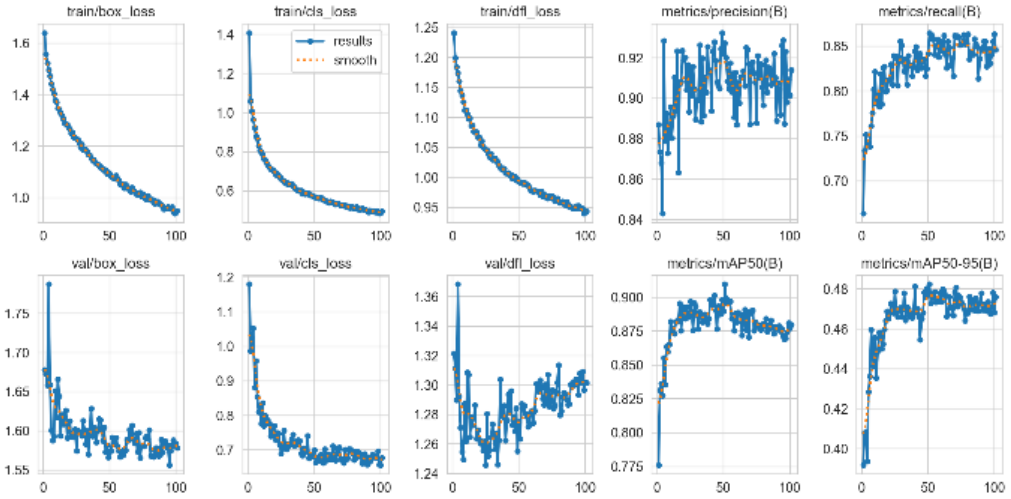
4.2. Implementasi Sistem dan Lingkungan Pengujian

Realisasi sistem kendali AC adaptif berbasis *Edge* AIoT ini diimplementasikan secara lokal dalam bentuk simulasi arsitektur perangkat lunak. Perangkat komputasi (*edge server*) yang digunakan untuk mengeksekusi pemrosesan visi komputer (YOLOv8n) serta bertindak sebagai MQTT *local broker* menggunakan spesifikasi teknis berupa memori RAM sebesar 20 GB, penyimpanan SSD sebesar 1,5 TB, dan dukungan kartu grafis NVIDIA GeForce RTX 4050. Komputasi GPU lokal ini krusial

untuk memastikan proses inferensi citra berjalan minim latensi. Hasil kalkulasi kepadatan ruangan dari model tersebut secara otomatis diubah oleh program Python menjadi instruksi logis penyesuaian suhu, yang selanjutnya ditransmisikan dalam bentuk *payload data string* menuju topik jaringan simulasi.

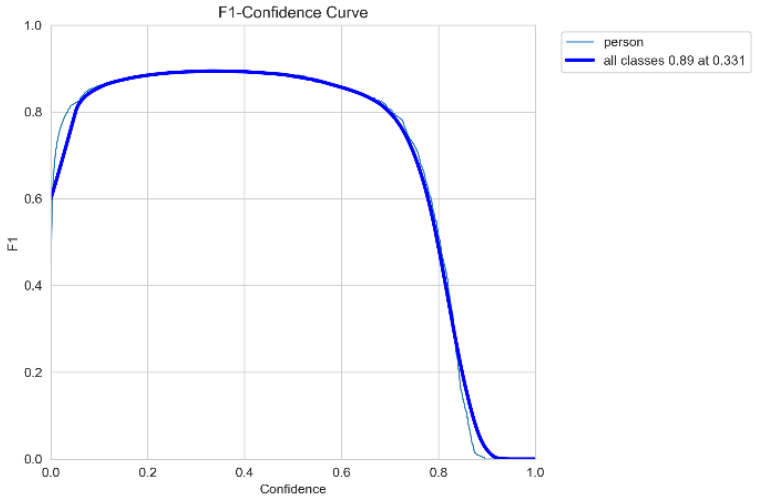
4.3. Evaluasi Performa Model YOLOv8

Pelatihan model YOLOv8n dieksekusi di lingkungan komputasi awan Kaggle menggunakan akselerator GPU Tesla T4. Konfigurasi *training* mengikuti metodologi yang ditetapkan: batas maksimal 300 *epoch*, *batch size* 16, resolusi citra 640x640 piksel, dan menggunakan *optimizer* AdamW dengan *learning rate* awal 0.001. Untuk mencegah terjadinya *overfitting* dan menjaga efisiensi sumber daya komputasi, mekanisme *Early Stopping* diterapkan dengan parameter *patience* sebesar 50 *epoch*. Berdasarkan log pelatihan yang divisualisasikan pada Gambar 4, proses iterasi secara otomatis berhenti pada *epoch* ke-101. Hal ini membuktikan bahwa model telah mencapai titik konvergensi, di mana arsitektur merekam performa paling optimal (*best weight*) pada *epoch* ke-51.



Gambar 4 Grafik Loss/mAP

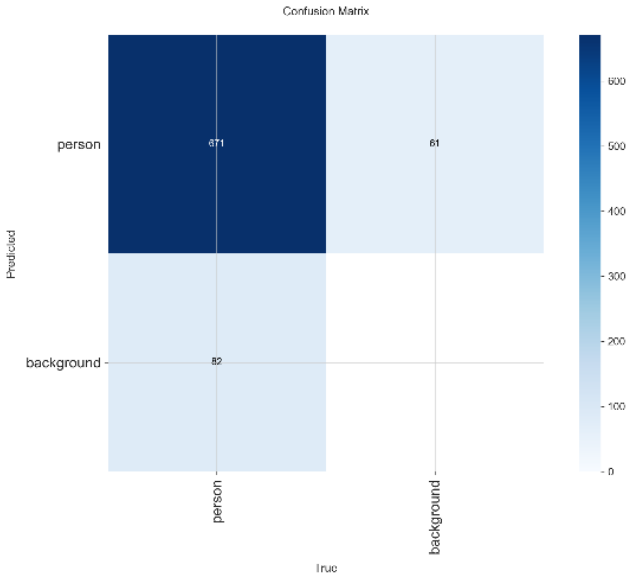
Hasil evaluasi kuantitatif dari model terbaik tersebut mencatatkan tingkat pengenalan yang sangat presisi pada skenario simulasi *indoor*. Model memperoleh nilai mAP@50 (Mean Average Precision) sebesar 0.910 (91%), yang mengindikasikan tingginya akurasi lokalisasi *bounding box* terhadap target. Tingkat kepresisian (*Precision*) mencapai 0.926 (92.6%), yang bermakna bahwa sistem sangat kebal terhadap prediksi positif palsu, sebuah faktor krusial untuk mencegah aktuator AC menyala saat ruangan kosong. Sementara itu, nilai *Recall* sebesar 0.865 (86.5%) menunjukkan sensitivitas algoritma yang andal dalam mengidentifikasi objek manusia meskipun terdapat tantangan oklusi pada skenario *High Occupancy*. Analisis lebih lanjut pada kurva F1-Confidence memperlihatkan bahwa keseimbangan metrik terbaik (F1-Score 0.89) dicapai pada ambang batas *confidence* 0.331.



Gambar 5 Kurva F1-Confidence

Keandalan model dalam menekan metrik kesalahan deteksi juga dikonfirmasi melalui *Confusion Matrix* Matriks tersebut menunjukkan keberhasilan model memprediksi 671 objek secara benar (*True Positive*), dengan angka *False Positive* yang sangat rendah (61 kejadian). Hal ini membuktikan efektivitas injeksi *negative samples* yang dilakukan pada tahap prapemrosesan data. Secara kualitatif, komparasi antara anotasi *Ground Truth* dan prediksi model memperlihatkan kemampuan *bounding box* yang presisi dan konsisten di berbagai sudut pandang kamera. Sebagai validasi akhir untuk kelayakan *edge computing*, model mencatatkan waktu inferensi sebesar 2.6ms per citra, memastikan bahwa integrasi dengan

mikrokontroler IoT dapat berjalan secara *real-time* tanpa adanya latensi pemrosesan visual.



Gambar 6 Confussion Matrix

4.4. Perbandingan dengan Penelitian Terdahulu

Hasil evaluasi model YOLOv8n pada penelitian ini, dengan nilai mAP@50 sebesar 91% dan Precision sebesar 92,6%, menunjukkan tingkat performa yang sejalan dengan hasil-hasil yang dilaporkan pada penelitian berbasis arsitektur YOLO sejenis. Pesik [7] yang juga menerapkan YOLOv8 untuk deteksi dan penghitungan objek manusia melaporkan bahwa arsitektur ini secara konsisten menghasilkan akurasi deteksi yang tinggi pada skenario indoor, sementara Puspita dkk. (2025) membuktikan bahwa penerapan augmentasi data tingkat lanjut mampu mendorong performa YOLO tetap optimal meskipun pada objek dengan tingkat oklusi tinggi. Nilai Recall pada penelitian ini yang relatif lebih rendah (86,5%) dibandingkan Precision (92,6%) mengindikasikan bahwa model masih mengalami sejumlah kegagalan dalam mengenali seluruh objek manusia pada kondisi tertentu, terutama pada skenario *High Occupancy* di mana objek manusia cenderung saling bertampalan (*overlapping*) dan sebagian tubuh terhalang oleh objek lain di dalam ruangan. Kecenderungan ini konsisten dengan temuan Puspita [9] yang menyatakan bahwa oklusi antarobjek merupakan salah satu tantangan utama yang memengaruhi sensitivitas deteksi pada arsitektur YOLO, sekalipun tingkat presisinya tetap terjaga tinggi.

4.5. Hasil Black Box Testing

Untuk memvalidasi keandalan integrasi sistem antara hasil deteksi objek dan pengiriman instruksi kendali otomatis, dilakukan pengujian *Black Box* dengan total 800 skenario *scanning* acak yang diambil dari data uji. Hasil pengujian fungsionalitas disajikan secara detail pada Tabel 2.

Tabel 2 Hasil Pengujian Black Box Sistem Kendali

Kategori	Jumlah Scanning	Sukses	Gagal
Empty	100	98	2
Low	500	485	15
High	200	188	12
Total	800	771	29

Berdasarkan data pada Tabel 2, rata-rata tingkat keberhasilan (*success rate*) transmisi logika kendali secara keseluruhan mencapai angka 96,38%. Kegagalan fungsionalitas paling tinggi ditemukan pada kategori *High Occupancy* dengan nilai *success rate* sebesar 94,00%. Melalui analisis pola kesalahan, kegagalan ini murni dipicu oleh tingginya efek oklusi (objek manusia yang saling bertumpukan atau terhalang fasilitas ruangan) pada skenario ruangan padat. Kondisi tersebut menyebabkan algoritma YOLOv8n mengalami sedikit galat dalam menghitung jumlah total manusia sesungguhnya, yang berujung pada terjadinya *mismatch* pengiriman *payload* instruksi suhu. Namun secara menyeluruh, hasil pengujian ini membuktikan bahwa arsitektur perangkat lunak yang dibangun memiliki tingkat keandalan dan konsistensi yang sangat tinggi dalam menerjemahkan informasi visual menjadi instruksi logika kendali secara *real-time*. Tingkat keberhasilan transmisi instruksi kendali sebesar 96,38% yang diperoleh pada penelitian ini menunjukkan konsistensi arsitektur perangkat lunak yang dibangun dalam menerjemahkan hasil deteksi visual menjadi *payload* instruksi kendali secara andal. Temuan ini memperkuat argumentasi yang disampaikan oleh Kusuma [13] bahwa protokol MQTT unggul dalam efisiensi dan keandalan transmisi data pada sistem IoT dibandingkan protokol HTTP konvensional, khususnya pada skenario yang menuntut respons

real-time dengan *overhead* komunikasi yang minim. Sejalan pula dengan hasil pengujian QoS jaringan yang dilaporkan oleh Pono [23] tingkat kegagalan yang relatif kecil pada penelitian ini (3,62%) mengindikasikan bahwa arsitektur simulasi berbasis MQTT yang diusulkan cukup layak untuk dikembangkan lebih lanjut menuju implementasi pada jaringan IoT yang sesungguhnya.

4.6. Keterbatasan Penelitian

Penelitian ini memiliki beberapa keterbatasan yang perlu diperhatikan dalam menginterpretasikan hasil yang diperoleh. Pertama, keseluruhan sistem kendali yang diusulkan baru diuji dalam bentuk simulasi arsitektur perangkat lunak, dan belum divalidasi pada perangkat keras fisik seperti mikrokontroler ESP32 maupun modul *transmitter* IR yang sesungguhnya, sehingga faktor-faktor non-ideal pada implementasi nyata seperti gangguan jaringan atau keterbatasan daya perangkat belum tercakup dalam evaluasi ini. Kedua, dataset yang digunakan sebagian besar merepresentasikan kondisi ruang kelas dan ruang perkantoran dengan karakteristik pencahayaan tertentu, sehingga generalisasi model terhadap tipe ruangan lain dengan kondisi visual yang berbeda secara signifikan masih perlu diuji lebih lanjut. Ketiga, penelitian ini belum mempertimbangkan variabel lingkungan tambahan seperti suhu eksternal dan tingkat kelembapan udara dalam logika kendali suhu, yang berpotensi memengaruhi keakuratan rekomendasi suhu optimal pada kondisi dunia nyata. Keterbatasan-keterbatasan ini menjadi dasar bagi arah pengembangan penelitian selanjutnya sebagaimana diuraikan pada subbagian Saran.

5. KESIMPULAN

5.1. Kesimpulan

Berdasarkan hasil penelitian dan simulasi arsitektur yang telah dilakukan, integrasi algoritma YOLOv8n dalam arsitektur *Edge* AIoT terbukti sangat efektif untuk mengotomatisasi logika kendali penyejuk ruangan berdasarkan tingkat kepadatan manusia secara *real-time*. Injeksi *negative samples* pada tahap prapemrosesan berhasil menekan angka kesalahan deteksi (*False Positive*) secara signifikan saat ruangan dalam kondisi kosong. Evaluasi kuantitatif terhadap model terbaik menunjukkan performa lokalisasi yang presisi dengan nilai mAP@50 sebesar 91% dan tingkat presisi 92,6%. Lebih lanjut, hasil pengujian fungsional menggunakan metode *Black Box Testing* mencatatkan tingkat keberhasilan (*success rate*) rata-rata sebesar 96,38% dalam mentransmisikan *payload* instruksi suhu secara tepat melalui protokol MQTT sesuai dengan kelas okupansi ruangan. Dengan waktu inferensi visual yang sangat rendah, yakni 2,6ms per citra, arsitektur simulasi ini terbukti andal, responsif, dan sangat layak untuk dikembangkan sebagai cetak biru (*blueprint*) sistem otomasi bangunan pintar ke depan.

5.2. Saran

Untuk pengembangan penelitian selanjutnya, implementasi perangkat keras secara menyeluruh menggunakan mikrokontroler aktuator (seperti ESP32) dan modul IR pada unit AC fisik sangat disarankan untuk mengukur efisiensi *Quality of Service* (QoS) pada jaringan MQTT yang sesungguhnya. Selain itu, penambahan variabel sensor lingkungan seperti suhu di luar ruangan (suhu eksternal) dan tingkat kelembapan dapat diintegrasikan bersama data visual YOLOv8 untuk menciptakan algoritma penyesuaian kenyamanan termal yang lebih komprehensif.

REFERENSI

[1] A. S. P. Pamungkas, T. Taqiyuddin, and D. P. Setianingsih, "Evaluasi Indeks Konsumsi Energi Listrik pada Gedung Administrasi PT. X," *Jurnal Teknik Elektro Uniba (JTE UNIBA)*, vol. 9, no. 2, pp. 607–614, Apr. 2025, doi: 10.36277/jteuniba.v9i2.1257.

[2] E. Penggunaan *et al.*, "Edukasi Penggunaan Energi Listrik dan Fasilitas Kantor yang Efisien dan Aman," vol. 7, no. 2, pp. 2684–9887, 2025, doi: 10.53860/losari.v7i2.489.

[3] I. Santoso, A. M. Manurung, and E. R. Subhiyakto, "Comparison of ResNet-50, EfficientNet-B1, and VGG-16 Algorithms for Cataract Eye Image Classification," *Journal of Applied Informatics and Computing*, vol. 9, no. 2, pp. 284–294, Mar. 2025, doi: 10.30871/jaic.v9i2.8968.

[4] Z. S. Hidayat, Y. A. Wijaya, and R. Kurniawan, "OPTIMIZING YOLOV8 FOR AUTONOMOUS DRIVING: BATCH SIZE FOR BEST MEAN AVERAGE PRECISION (MAP)," *Jurnal Teknik Informatika (Jutif)*, vol. 5, no. 4, pp. 1147–1153, Jul. 2024, doi: 10.52436/1.jutif.2024.5.4.1626.

[5] D.- Afandi, "Rancang Bangun Sistem Kendali AC dengan sensor DHT22 dan PIR Dalam Ruangan Menggunakan Mikrokontroller Arduino Nano," *JURNAL MEDIA INFOTAMA*, vol. 21, no. 1, pp. 187–193, Apr. 2025, doi: 10.37676/jmi.v21i1.7787.

[6] F. A. Hidayat, F. R. Umbara, and R. Ilyas, "Implementasi Yolo Untuk Menghitung Kepadatan Kendaraan Tempat Parkir," *Jurnal Algoritma*, vol. 22, no. 2, Nov. 2025, doi: 10.33364/algoritma/v.22-2.2919.

[7] Mihuandayani, W. H. Sefranda Pesik, S. Mamuaya, Akbar Nuzul Putra, and E. Mulyaman, "Implementasi YOLOv8 untuk Deteksi dan Hitung Objek Manusia dengan Convolutional Neural Network," *Buffer Informatika*, vol. 11, no. 1, pp. 16–26, Apr. 2025, doi: 10.25134/buffer.v11i1.356.

[8] Hamdani Hamdani, Sirojul Hadi, and Jian Budiarto, "Sistem Kendali Peralatan Elektronik Rumah Tangga Berbasis Internet Of Things Menggunakan Protokol MQTT".

[9] R. F. Puspita, M. Naufal, and F. Al Zami, "Improving YOLO Performance with Advanced Data Augmentation for Soccer Object Detection," *Journal of Applied Informatics and Computing*, vol. 9, no. 6, pp. 3601–3611, Dec. 2025, doi: 10.30871/jaic.v9i6.11256.

[10] J. Homepage and I. Alfath Zulkarnain, "MALCOM: Indonesian Journal of Machine Learning and Computer Science Yolov11 Optimization Through Hyperparameter Tuning and Data Augmentation to Improve Vehicle Detection Accuracy at Night Optimasi Yolov11 Melalui Hyperparameter Tuning dan Data Augmentasi untuk Meningkatkan Akurasi Deteksi Kendaraan pada Kondisi Malam Hari," vol. 5, pp. 1294–1303, 2025, doi: 10.57152/malcom.v5i4.2250.

[11] J. Jimmy, J. Johan, A. Suwandhi, and B. Benny, "Penerapan Edge AI untuk Smart Home Deteksi Aktivitas Penghuni Berbasis IoT," *Jurnal Minfo Polgan*, vol. 14, no. 2, pp. 3156–3163, Dec. 2025, doi: 10.33395/jmp.v14i2.15658.

[12] M. Nabil Zamzami, "Integrasi WSN dan IoT Untuk Sistem Monitoring Rumah Cerdas Berbasis MQTT," *Karapan Network S Journal*, vol. I, No.I, 2025, doi: 10.20473/KNJ.I.I.612-623.

[13] F. C. Kusuma, N. B. A. Karna, and A. I. Irawan, "Analisis Perbandingan Quality of Services (QoS) Protokol HTTP dan MQTT pada Sistem Monitoring Berat Ayam Broiler Berbasis IoT," *Jurnal Nasional SAINS dan TEKNIK*, vol. 2, no. 1, pp. 16–22, Jul. 2024, doi: 10.25124/jnst.v2i1.7987.

[14] D. Suryadi, C. S. Octiva, T. I. Fajri, U. W. Nuryanto, and M. L. Hakim, "Optimasi Kinerja Sistem IoT Menggunakan Teknik Edge Computing," *Jurnal Minfo Polgan*, vol. 13, no. 2, pp. 1456–1461, Sep. 2024, doi: 10.33395/jmp.v13i2.14102.

[15] A. Herwandi, A. A. Ramadhan, N. T. Sunggono, and F. Ferawati, "Analisis Kinerja ESP32-CAM Dalam Mendeteksi Objek," *bit-Tech*, vol. 7, no. 3, pp. 1014–1021, Apr. 2025, doi: 10.32877/bt.v7i3.2296.

[16] Glenn Jocher, Ayush Chaurasia, and Jing Qiu, "Ultralytics YOLOv8 (Version 8.0.0) [Computer software]," 2023, 8.0.0. Accessed: Jul. 08, 2026. [Online]. Available: https://github.com/ultralytics/ultralytics

[17] D. Dewa and A. Rahman, "KLASIFIKASI PENYAKIT DAUN ANGGUR MENGGUNAKAN EFFICIENTNETV2-B0 DENGAN OPTIMIZER ADAMW DAN SGD," *JATI (Jurnal Mahasiswa Teknik Informatika)*, vol. 10, no. 1, pp. 632–640, Jan. 2026, doi: 10.36040/jati.v10i1.16847.

[18] I. D. G. A. W. Natih, M. W. A. Kesiman, and I. M. G. Sunarya, "Analisis Perbandingan Arsitektur dan Optimizer YOLOv11 untuk Estimasi Buah Kelapa," *RIGGS: Journal of Artificial Intelligence and Digital Business*, vol. 4, no. 4, pp. 12–19, Nov. 2025, doi: 10.31004/riggs.v4i4.3329.

[19] K. -, M. N. Nrul Haq, N. Nurtiara, and S. P. Martana, "ANALISIS KENYAMANAN TERMAL PADA RUANG KELAS PRODI AKUNTANSI 4307 DI UNIKOM," *DESA - DESIGN AND ARCHITECTURE JOURNAL*, vol. 6, no. 1, pp. 25–37, Sep. 2025, doi: 10.34010/k4rj3851.

[20] A. R. Pramudya, W. Riyanto, F. Hilmy, and R. M. Sulistiyo, "Analisis Penggunaan Blower Terhadap Desain Kenyamanan Termal Rumah Instan Sederhana Sehat di Kota Surakarta Dengan Metode Computational Fluid Dynamics (CFD)," *Metrotech (Journal of Mechanical and Electrical Technology)*, vol. 4, no. 3, pp. 179–187, Sep. 2025, doi: 10.70609/metrotech.v4i3.7258.

[21] F. H. M. D. Qornain, B. Tjahjono, G. Firmansyah, and M. H. Arfian, "Rancang Bangun Sistem Kontrol Suhu Berbasis Internet Of Things (IoT) untuk Efisiensi Energi Pendingin Ruangan Menggunakan Metode Prototype," *Jurnal Sosial Teknologi*, vol. 6, no. 1, pp. 87–100, Jan. 2026, doi: 10.59188/jurnalsostech.v6i1.32651.

[22] T. Takyudin, M. S. Rais, J. A. Putra, and A. Hamsar, "Metode Deteksi dan Estimasi Luas Lubang Jalan Menggunakan Deep Learning Berbasis YOLOv11," *RIGGS: Journal of Artificial Intelligence and Digital Business*, vol. 4, no. 2, pp. 6786–6790, Jul. 2025, doi: 10.31004/riggs.v4i2.1760.

[23] Viky G.L. Radja Pono, Indah Octaviani Laleb, and Demas Eklopas Neno, "Implementasi Quality of Service (QoS) pada Jaringan Intra Pemerintah," *Jurnal Teknologi dan Manajemen Industri Terapan*, vol. 4, no. I, pp. 97–103, Mar.

2025, doi: 10.55826/jtmit.v4iI.789.